

1)

Question 01

	SOL	NOVO	CHO	QUE	LEO	PARO	ACT	NOA	SIM	NÃO
SIM	$\frac{2}{9}$	$\frac{1}{9}$	$\frac{3}{9}$	$\frac{2}{9}$	$\frac{1}{9}$	$\frac{3}{9}$	$\frac{3}{9}$	$\frac{6}{9}$	$\frac{8}{9}$	$\frac{6}{9}$
NÃO	$\frac{3}{5}$	$\frac{0}{5}$	$\frac{2}{5}$	$\frac{2}{5}$	$\frac{2}{5}$	$\frac{1}{5}$	$\frac{4}{5}$	$\frac{1}{5}$	$\frac{3}{5}$	$\frac{2}{5}$

  

NOVO	SIM (9/4)	NÃO (9/4)
SOL	$\frac{2}{9}$	$\frac{1}{9}$
CHO	$\frac{3}{9}$	$\frac{1}{9}$
NOA	$\frac{6}{9}$	$\frac{1}{9}$
NÃO	$\frac{6}{9}$	$\frac{2}{9}$

$= 0,02116$        $= 0,003423$

$0,012116$   
 $+ 0,00342$   


---

 $0,00458$

$\rightarrow \text{SIM} = 86,08\%$   
 $\text{NÃO} = 13,91\%$

2) Google colab : <https://colab.research.google.com/drive/1q-k6CaJqywB1rFmcpyFd0Lrfnyk7qS4v?usp=sharing>

3) Google colab : <https://colab.research.google.com/drive/1q-k6CaJqywB1rFmcpyFd0Lrfnyk7qS4v?usp=sharing>

4) Google colab: <https://colab.research.google.com/drive/1q-k6CaJqywB1rFmcpyFd0Lrfnyk7qS4v?usp=sharing>

## 5) Resumo do artigo:

### I. INTRODUÇÃO

O Aprendizado em Conjunto é uma abordagem poderosa em Aprendizado de Máquina, que visa melhorar o desempenho de modelos ao combinar as previsões de múltiplos "aprendizes" ou modelos base. Este artigo explora os princípios, métodos e aplicações do Aprendizado em Conjunto, destacando seu papel essencial na obtenção de resultados mais precisos e robustos.

### II. VISÃO GERAL DO APRENDIZADO EM CONJUNTO

#### A. Combinando Base Learners

Uma das pedras angulares do Aprendizado em Conjunto é a combinação de múltiplos modelos base para criar um modelo mais poderoso. Isso pode ser feito de várias maneiras, incluindo votação (majoritária ou ponderada), média das previsões, ou até mesmo treinando um modelo meta que aprende a melhor maneira de combinar as saídas dos modelos base. A diversidade entre os modelos base é essencial para garantir melhorias significativas no desempenho.

#### B. Ensemble Selection

Selecionar quais modelos base incluir em um ensemble é uma decisão crítica. A diversidade é fundamental, pois modelos semelhantes podem não trazer benefícios substanciais. Métodos de seleção como Bootstrap, Random Subspace, e Random Forest ajudam a manter a diversidade no ensemble.

### **III. MÉTODOS DE APRENDIZADO EM CONJUNTO**

#### **A. Boosting**

O Boosting é uma técnica que se destaca na correção dos erros dos modelos base iterativamente. Modelos fracos são treinados em subconjuntos dos dados, e cada novo modelo é criado para enfatizar os exemplos que foram classificados incorretamente pelos modelos anteriores. Isso resulta em um modelo forte que se concentra nas áreas problemáticas do espaço de características.

#### **B. Bagging**

Bagging (Bootstrap Aggregating) é uma técnica que visa melhorar a estabilidade e a generalização do modelo, criando várias amostras bootstrap dos dados de treinamento e treinando modelos base independentes em cada amostra. As previsões desses modelos são então combinadas para produzir um resultado final.

#### **C. Stacking**

O empilhamento envolve a criação de um meta-modelo que aprende a combinar as previsões dos modelos base. Os modelos base são treinados em conjunto com dados de treinamento e, em seguida, o meta-modelo é treinado com as saídas dos modelos base como entradas. Isso permite que o meta-modelo ajuste as previsões dos modelos base para obter um melhor desempenho geral.

### **IV. APLICAÇÕES DO APRENDIZADO EM CONJUNTO NA LITERATURA RECENTE**

Esta seção explora exemplos recentes de como o Aprendizado em Conjunto tem sido aplicado em problemas do mundo real. Essas aplicações incluem classificação, regressão, detecção de anomalias e muito mais. Destaca-se como o Aprendizado em Conjunto tem sido essencial para alcançar resultados de ponta em uma variedade de domínios.

### **V. DISCUSSÕES E DIREÇÕES FUTURAS DE PESQUISA**

Discutimos as implicações e desafios do Aprendizado em Conjunto, como a seleção adequada de modelos base e a gestão da diversidade entre eles. Além disso, sugerimos várias direções de pesquisa para o futuro, como o desenvolvimento de métodos de Aprendizado em Conjunto adaptativos e a exploração de novas aplicações em campos emergentes.

### **CONCLUSÃO**

O Aprendizado em Conjunto é uma técnica poderosa que tem demonstrado consistentemente melhorar o desempenho dos modelos de Aprendizado de Máquina. Ao combinar modelos base de forma inteligente e diversificada, essa abordagem se tornou fundamental em uma variedade de aplicações. À medida que o campo continua a evoluir, podemos esperar avanços contínuos e novas descobertas que impulsionarão ainda mais o campo do Aprendizado de Máquina.